

GI41 算術符号

第15回

算術符号

算術符号とは、1960年頃にマサチューセッツ工科大学のP. Eliasによって提案された符号。

この符号化は、データ圧縮向きでJPEGにも採用されている。
ただし、基本的なアルゴリズムの特許はIBM等の企業がおさえている。

これらの算術符号関連の特許は、2003年頃までにすべて失効しています。
※米国の特許は出願から最大20年で失効。今はフリー…のはず

算術符号


算術符号は、記号列を「実数 0 と 1 の間の区間」を用いて、
区間を「記号の出現確率に比例した小区間に分割していく」ことで符号化を行う。

例)記号列 abbbc を符号化してみる。

記号は {a, b, c} の 3 種類。出現確率をそれぞれ 0.2, 0.6, 0.2 とする。



次ページへ



区間に含まれる値の中で最も情報量の少ない値を見つけて、その値を符号語とする。

算術符号

<浮動小数の符号化>

0.11296から0.1216までで2進数小数値を考えると...

$$1/16 + 1/32 + 1/64 = 0.109375 < \text{NG}$$

$$1/16 + 1/32 + 1/64 + 1/128 = 0.1171875 < \text{GOOD}$$

どうやら該当する値が見つかったようなので、2進数で表現してみる。

$$1/16 + 1/32 + 1/64 + 1/128 = 0.0001111(2進数)$$

この2進数の値を符号語として出力する。「0001111」

これで、abbbcの5文字が7ビットに圧縮されたことになる。

算術符号


<算術符号の復号>

復号するときは、符号語と出現確率からデータを特定し、その区間と符号語を出現確率によって変換して同じ処理を終了まで繰り返す。

例)記号は {a, b, c} の 3 種類。出現確率はそれぞれ 0.2, 0.6, 0.2 とする。

(この情報は符号に付加しておく)

符号語0001111(=0.1171875)を復号してみる。



<<算術符号の欠点>>

- (1) データの最後を判別できない . . . データ長を別で記録しておくなどで解決できる。
- (2) データが長いほどより多くの桁数が必要になる。また演算精度も問題になる。

そこで実数ではなく整数を使って符合化する方法が考案された。
それが Jones 法や、RangeCoder である。

RangeCoder

RangeCoder

RangeCoder とは、算術符号の整数演算バージョンであり、符号化区間をビット単位ではなく整数の範囲(range)で管理する手法です。

RangeCoder(レンジコーダ)は、算術符号の実用的なバリエーションの1つで、特に整数演算ベースで精度の高い圧縮が可能なため、さまざまな圧縮ソフト(例:7-ZipのLZMAなど)で使われています。

RangeCoder

算術符号では浮動小数点を扱っていたため丸目誤差などで正しく復号できない可能性があったがRangeCoderは整数を扱うので精度を気にする必要がない！

また整数の演算を行うので浮動小数点を使う算術符号より高速に動作する。
更に算術符号では曖昧だった特許の問題がないので自由に使うことが可能！

基本的にいいことづくめなので算術符号よりこっちを使おう！

RangeCoder

■基本的な考え方

算術符号は区間 $[0, 1)$ を分割していきますが、レンジコードは $[0, 1)$ を分割するのではなく、最初に大きな区間たとえば $[0, 1000)$ を設定して、それを小さな区間に分割していくことで符号化を行います。

レンジコードは整数で演算するので、記号列が長くなると当然ですが区間が狭くなって分割できなくなります。

そのときは区間を引き伸ばすことで対応します。

RangeCoder

たとえば、 $[0, 1000)$ を分割していくと $[123, 124)$ になりました。

もうこれ以上分割できませんね。

そこで、区間をたとえば 100 倍して $[12300, 12400)$ を分割することにします。

このとき、区間全体の大きさは $[0, 1000)$ ではなく、

それを 1000 倍した $[0, 100000)$ と考えるわけです。

RangeCoder

単純に考えると、区間を表すために多倍長整数が必要になりますが、区間を引き伸ばすタイミングを定めることにより、通常の整数演算でレンジコーダをプログラムすることができます。

また、区間全体の大きさも覚えておく必要はありません。

レンジコーダは分割した区間の幅 (range) と下限値 (low) だけで符号化することができます。

復号の処理でも、符号化と同じタイミングで range を引き伸ばしていくことで、符号語を記号列に復号することができます。

レンジコーダは区間の下限値を符号語として出力します。